작 업 기 록

보도자료 모니터

정부기관·지자체·공공기관 보도자료 수집기 + 연구·분양 바로가기

작성일	2026년 10월 22일 (앞선 판 9월 9일)
저장소	github.com/kwakmg74-michael/gov-press-monitor
화면	kwakmg74-michael.github.io/gov-press-monitor
현재 상태	수집 72곳 / 바로가기 48곳 / 테스트 475개 통과
실행 환경	Python 3, 서버PC 한 대에서 하루 세 번 자동 실행

01 한눈에 보기

보도자료를 매일 자동으로 모아, 기관·기간·검색어로 좁혀 볼 수 있는 웹 화면을 만드는 도구입니다. 화면은 외부 리소스를 전혀 불러오지 않는 HTML 파일 하나로 떨어지고, 그 파일이 그대로 웹사이트가 됩니다.

수집 대상 기관
72곳
게시판 기준으로는 73개

테스트
475개
네트워크 없이 전부 통과

다섯 개의 탭

탭	곳	하는 일	상태
정부기관	53	korea.kr 통합 창구 하나로 전 부처	수집
지자체	8	사이트별 어댑터 (서울 3, 경기 5) + 시·도·구보 바로가기	수집
공공기관	11	사이트별 어댑터 (게시판 12개)	수집
연구·업계	43	연구소 23 · 증권사 7 · 업계 10 · 협회 3	바로가기
분양	5	청약홈 · LH · SH · GH	바로가기

탭에 붙는 숫자는 **기사 건수가 아니라 기관 수**입니다. 기사 건수는 날마다 출렁이지만 '몇 곳을 훑고 있는가'는 그 탭이 무엇을 덮는지 말해 주기 때문입니다. 그날 표시되는 건수는 목록 위에 따로 나옵니다.

긁는 탭과 바로가기 탭

앞의 셋만 글을 모읍니다. 뒤의 둘은 가는 길만 놓습니다. 둘을 가른 기준은 **들이는 품에 견줘 나오는 것**이었습니다. 자세한 사정은 07·08절에 적었습니다.

화면이 하는 일

- **기관 체크박스** — 묶음별로 나뉘고 묶음 안은 가나다순. 그날 발표가 없던 기관도 늘 목록에 나옵니다(건수 0은 흐리게).
- **검색 기간** — `YY.MM.DD ~ YY.MM.DD` 직접 입력 + 오늘·7일·30일·전체 버튼
- **검색어** — 제목·요약·기관에서 찾고 결과에서 하이라이트. 검색·초기화 버튼이 따로 있습니다.
- **목록** — 제목 / 기관 · 날짜 · 담당부서가 한 줄에. 제목을 누르면 원문이 새 탭에서 열립니다.
- **서비스 문의** — 제목·내용·회신 이메일을 받아 메일로 보냅니다. 받는 주소는 화면에 드러나지 않습니다.

결과물

파일	내용
`articles.db`	SQLite. `(source, uid)` 기준으로 중복 저장되지 않으므로 매일 돌려도 계속 쌓입니다.
`docs/index.html`	외부 리소스를 전혀 불러오지 않는 파일 하나. 이 폴더가 그대로 GitHub Pages 사이트가 됩니다.
`docs/stamp.txt`	마지막 수집 시각 한 줄. 열어 둔 탭이 낡았는지 알아내는 데 씁니다(12절).

02 왜 처음부터 다시 만들었나

이 프로젝트에는 앞선 버전이 있었습니다. 돌아가긴 했는데 결과물이 이상했고, "느낌이 별로"라는 것이 다시 시작하게 된 계기였습니다. 코드를 열어 보니 그 느낌에는 분명한 근거가 있었습니다.

증상

무엇이	어떻게 나왔나
수집 건수	216건 — 실제 보도자료보다 훨씬 많음
게시일	**전부 비어 있음**
제목	"보도자료", "공지사항" 같은 메뉴 이름이 기사로 섞여 들어옴

원인

파서가 페이지 안의 모든 링크를 훑으면서, 링크 글자에 `보도 · 뉴스 · 공지 · 자료` 중 하나라도 들어 있으면 기사로 담고 있었습니다. 그러니 왼쪽 메뉴의 "보도자료" 링크도, 하단 배너의 "자료실"도 전부 기사가 됐습니다. 목록의 **구조**를 보는 게 아니라 **글자**를 보고 있었던 겁니다.

> **이런 실패가 위험한 이유**
> 오류가 나지 않습니다. 조용히 잘못된 데이터를 쌓습니다. 216건이라는 숫자만 보면 잘 돌아가는 것처럼 보이고, 날짜가 비었다는 걸 알아차리려면 목록을 직접 들여다봐야 합니다. 그래서 이번에는 **"무엇이 들어오면 안 되는가"를 테스트로 먼저 고정**했습니다.

다시 만들 때 세운 기준

1. **파싱과 네트워크를 분리한다.** 목록 HTML을 받아 결과 목록으로 바꾸는 함수는 순수 함수로 두고, 받아 오는 일은 따로 분리합니다.
2. **실제 페이지를 저장해 fixture로 쓴다.** 만들어 낸 예시가 아니라 그 사이트에서 실제로 받은 HTML을 `tests/fixtures/`에 넣고 그걸 대상으로 테스트합니다.
3. **구조를 확인하지 않은 기관은 목록에 넣지 않는다.** 짐작해서 쓴 파서는 조용히 실패하기 때문에, 확인 전에는 `PENDING`에만 적어 둡니다.
4. **품질 기준을 저장 직전에 건다.** 제목·링크·게시일·고유 ID가 하나라도 비면 버립니다.

이 네 가지가 이후 모든 작업의 뼈대가 됐습니다. 기관을 하나 붙일 때마다 "실제 HTML 저장 → 파서 작성 → 테스트 통과 → 목록에 등록" 순서를 지켰습니다. 지금까지 이 순서를 어겨서 생긴 사고는 없습니다.

03 전체 구조



파일	줄	역할
`models.py`	126	Article 모델, 다섯 분류(탭) 정의, 날짜·텍스트 정규화
`boards.py`	526	게시판 수집 공통 뼈대 — Site, 받아 오기, TLS 후퇴, 중복 제거, 시간 상한
`korea_kr.py`	293	korea.kr 목록 파싱과 페이지 순회 (정부기관 전용)
`local_gov.py`	561	지자체 8곳 어댑터, 지역 묶음, 시·도·구보 주소
`public_org.py`	547	공공기관 11곳 어댑터, 분야 묶음
`research.py`	729	연구·업계 바로가기 43곳 (수집기는 남겨 둠)
`presale.py`	48	분양 바로가기 5곳
`agencies.py`	259	정부부처 코드표 53곳, 조직도 기준 구분·소속, 줄임말 해석
`storage.py`	197	SQLite 저장, 중복 제거, 조회
`dashboard.py`	1485	단일 HTML 화면 생성, 게시 폴더 만들기
`daily.py`	163	다른 PC가 올린 것 받기, git으로 올리기, 기록 남기기
`__main__.py`	550	명령줄 진입점

boards.py를 따로 뺀 이유

처음에는 지자체 수집기 하나뿐이라 모든 게 `local_gov.py` 안에 있었습니다. 공공기관·연구소를 붙이면서 **세 모듈이 필요로 하는 일이 완전히 같다**는 게 분명해졌습니다 — 목록 주소를 만들고, 받아 오고, 파서에 넘기고, 저장 형식으로 바꾼다.

그래서 공통분모를 `boards.py`로 뽑았습니다. TLS 처리를 고치면 세 곳에 한꺼번에 반영되고, 새 분류를 붙일 때 베껴 쓸 코드가 거의 없습니다.

Article — 모든 수집기의 공통 출력

```
Article(
    source,        # 출처 열쇠 (local:서울시, public:금융감독원 …)
    uid,           # 그 출처 안에서 고유한 글 번호
    agency,        # 화면에 뜨는 기관 이름
    title, link, published_at,
    summary,       # 담당부서 또는 요약
    category,      # 정부기관 / 지자체 / 공공기관 / 연구소 / 분양
)
```

수집기가 무엇이든 이 형태로만 넘기면 저장·중복제거·탭 배치가 자동으로 됩니다. `(source, uid)`가 중복 방지의 열쇠라서, 기관끼리 글 번호가 겹쳐도 안전합니다.

04 정부기관 — 통합 창구를 찾은 것이 컸다

부처가 53곳이니 어댑터도 53개가 필요할 거라 생각하기 쉽습니다. 그런데 **대한민국 정책브리핑(korea.kr)**이 전 부처 보도자료를 한곳에 모아 제공하고 있었습니다. 어댑터 하나로 53곳을 덮습니다.

목록 단계에서 필요한 게 다 채워진다

korea.kr 목록에는 제목·부처·게시일·원문 링크가 모두 들어 있습니다. 상세 페이지를 따로 열 필요가 없어서 요청 수가 크게 줄었습니다.

서버가 걸러 준다

더 중요한 발견은 **부처·기간·검색어를 서버에서 걸러 준다**는 점이었습니다. 다 받아 온 뒤 버리는 게 아니라 필요한 것만 요청하므로 훨씬 빠르고 사이트에도 부담이 적습니다.

파라미터	거르는 기준
`repCode`	발행 부처 (54개 코드를 조직도 기준으로 정리)
`srchWord`	검색어
`startDate / endDate`	기간
`pageIndex`	페이지

기관 이름은 정부 조직도를 기준으로

조직 개편으로 이름이 바뀐 기관이 많아서, 옛 이름이나 줄임말로 입력해도 찾아가도록 별칭을 정리했습니다.

입력	찾아가는 기관
특허청	지식재산처
통계청	국가데이터처
문화재청	국가유산청
산업통상자원부	산업통상부
여성가족부	성평등가족부

여러 기관으로 나뉜 경우에는 어디로 갔는지 알려 줍니다.

```
$ python -m govpress collect --dept 기획재정부
오류: 기획재정부는 기획예산처와 재정경제부로 나뉘었습니다.
      후속 기관 이름으로 지정하세요.
```

> **제외 목록**
>
> 국무조정실은 목록에서 뺐는데, 전 부처를 훑을 때 기사가 딸려 들어와 계속 다시 나타났습니다. 그래서 **수집 단계와 표시 단계 양쪽에서** 거르도록 `EXCLUDED`를 뒀습니다. 한쪽만 막으면 다른 쪽으로 새어 나옵니다.

05 지자체 — 통합 창구가 없다

지자체에는 korea.kr 같은 통합 창구가 없습니다. 사이트마다 게시판 소프트웨어가 달라서 어댑터가 하나씩 필요합니다. 우선 8곳을 붙였습니다.

지역	기관	파서	페이지 파라미터	관보
서울	서울시	`parse_seoul`	`curPage`	시보
	강동구	`parse_gangdong`	`cp`	구보
	송파구	`parse_standard_board`	`pageIndex`	구보
경기	경기도	`parse_gyeonggi`	`page`	도보
	구리시	`parse_standard_board`	`pageIndex`	시보
	성남시	`parse_seongnam`	`cntPerPage` (건수 방식)	시보
	용인시	`parse_yongin`	`q_currPage`	시보
	하남시	`parse_card_board`	`pageIndex`	시보

8곳에 게시판 종류가 넷, 페이지 파라미터가 다섯 가지였습니다. 이 제각각을 파악하는 데 시간이 제일 많이 들었습니다.

정렬 — 광역이 먼저

처음에는 지역 안을 가나다순으로만 정렬해서 서울 묶음이 "강동구 · 서울시 · 송파구"로 나왔습니다. 광역자치단체가 가운데 끼어 있으니 눈에 안 들어옵니다. **광역을 맨 앞에 고정**하도록 바꿨습니다. 이름을 코드에 박아 넣는 대신 `metro=True` 표시를 뒀습니다.

담당부서 칸 찾기 — 자리를 고정하지 않는다

송파구와 구리시는 같은 행정표준 게시판인데도 칸 수가 달랐습니다. 송파는 4칸, 구리는 '파일' 칸이 끼어 5칸입니다. 담당부서를 세 번째 칸으로 고정해 뒀더니 구리시에서 엉뚱한 값이 들어왔습니다.

> **해결 방식**
> 자리를 세는 대신 **뒤에서부터 날짜처럼 보이는 칸을 찾고, 그 바로 앞 칸을 담당부서로 봅니다.** 칸이 하나 늘거나 줄어도 견딥니다. 이 방식은 나중에 공공기관·연구소에서도 그대로 통했습니다.

성남시 — 페이지를 넘길 수 없는 게시판

성남시는 페이지 이동이 POST로만 됩니다. 주소로는 2페이지를 요청할 방법이 없었습니다. 대신 `cntPerPage`로 **한 번에 받을 건수를 늘릴** 수 있었습니다. 그래서 이 사이트만 "페이지를 넘기는" 대신 "한 번에 많이 받는" 방식(`page_mode="size"`)으로 처리합니다.

처음에는 이걸 모르고 30건 → 60건 → 90건을 겹쳐 받아, 같은 글을 세 번씩 다시 읽고 있었습니다. 지금은 한 번만 요청합니다.

시·도·구보 — 긁지 않고 바로가기로

기관 이름·건수 옆에 작은 딱지(`시보` `구보` `도보`)를 붙였습니다. 누르면 그 지자체의 관보가 새 창으로 열립니다. 여덟 곳 모두 있습니다.

> **왜 긁지 않았나**
>
> 받아서 열어 보니 셋 다 **호수 목록**이었습니다 — "제4186호 2026.10.15"처럼요. 개별 고시는 PDF 안에 들어 있고, 그 PDF가 116MB, 어떤 호는 348MB였습니다. 긁어 봐야 "이번 주 호가 나왔다"는 것밖에 알 수 없습니다. 경기도보는 아예 자바스크립트로 그리는 화면이라 받아 와도 빈 껍데기였습니다.
>
> 다만 지자체마다 **고시·공고 게시판**이 따로 있고(서울 `news_notice.do`, 경기 `bsIdx=469`, 성남 `pm010301`) 그쪽은 개별 건이 제목으로 늘어섭니다. 긁는다면 그쪽이 맞습니다. 아직 확인 전입니다.

딱지는 체크박스 **바깥**에 둡니다. 안에 넣으면 딱지를 누를 때 체크박스까지 켜져서 목록이 그 기관만 남습니다. 테스트로 고정해 뒀습니다.

제외한 곳

남양주시는 개발자도구 감지 페이지가 떠서 정상 목록을 받을 수 없었습니다. 목록에 넣지 않았습니다.

06 공공기관 — 6곳에서 11곳으로

지자체와 사정이 같습니다. 다만 붙여 보니 **지자체보다 훨씬 고릅니다**. 상당수가 정부 표준 CMS를 쓰기 때문입니다. 9월에 6곳이던 것이 11곳(게시판 12개)이 됐습니다.

분야	기관	비고
부동산	한국부동산원	
	한국토지주택공사 (LH)	
	서울주택도시개발공사 (SH)	보도자료 · 해명자료 게시판 둘
	경기주택도시공사 (GH)	
	한국주택금융공사	
	한국산업단지공단	구형 TLS
금융	금융감독원	담당부서 있음
	한국은행	
	한국소비자원	구형 TLS, 담당부서 있음
기타	식품안전정보원	
	한국인터넷진흥원	구형 TLS

한 기관에 게시판이 여럿일 때

서울주택도시개발공사는 보도자료와 해명자료가 따로 있습니다. 문제는 기관 이름이 두 가지 일을 겸하고 있었다는 점입니다 — 화면에 보이는 이름이자, 중복 저장을 막는 열쇠. 게시판이 둘이면 열쇠가 겹쳐 서로 덮어씁니다.

열쇠를 게시판 단위로, 이름을 기관 단위로 나눠서 해결했습니다.

```
_site("서울주택도시개발공사", "부동산", "…m_139/list.do", "page",
      parse_sh, board="보도자료"),
_site("서울주택도시개발공사", "부동산", "…m_612/list.do", "page",
      parse_sh, board="해명자료"),
```

저장 열쇠(`source`)만 갈라지고, 화면에는 기관 이름 하나로 나오며 결과는 날짜순으로 섞입니다. 체크박스도 하나고, 탭 숫자도 한 곳으로 셉니다.

07 연구·업계 — 긁다가 바로가기로 바꾼 이야기

9월 판에는 "연구소 2곳 / 확장 중"이라고 적혀 있었습니다. 그 뒤로 여섯 곳까지 늘렸는데, 늘릴수록 수지가 맞지 않는다는 게 분명해졌습니다.

숫자가 말해 준 것

	들인 품	나온 것
연구기관 6곳	게시판 구조가 제일 까다로움 — 카드형 목록, 목록에 날짜가 없는 곳(KDI), 상세를 열어야 발간일을 아는 곳	여섯 곳을 합쳐 **한 달 22건**

하루 세 번 두드려서 한 달에 스물두 건입니다. 게다가 KDI는 목록에 날짜가 없어 상세 페이지를 따로 열어야 했고, 그걸 위해 "새 글만 골라 최대 20개까지만 연다"는 장치를 따로 만들어야 했습니다.

> **판단**
> 연구기관은 "그 기관이 요즘 뭘 내놓나"를 둘러보는 자리지, "오늘 무슨 일이 있었나"를 훑는 자리가 아닙니다. 그래서 **글을 긁지 않고 가는 길만 놓기로** 했습니다. 대신 여섯 곳에 묶여 있던 품을 풀어서 마흔세 곳으로 넓혔습니다.

지금 구성

묶음	곳	예
연구소	23	국토연구원, KDI, 조세재정연구원, KB·하나·우리금융 연구소, IMF, OECD …
증권사	7	NH·IBK·교보·대신·삼성·신한·키움
업계	10	CBRE, 세빌스, 쿠쉬먼앤드웨이크필드, 알스퀘어, 이지스자산운용 …
협회	3	금융투자협회, 전국은행연합회, 한국경제인협회

주소는 대문으로

바로가기 주소는 게시판이 아니라 **홈페이지 대문**을 가리킵니다. 게시판 주소는 사이트 개편 한 번에 죽지만 대문은 오래 갑니다. 한 칸 더 들어가는 예외는 셋뿐입니다 — 한국어 페이지가 따로 있는 곳(쿠쉬먼앤드웨이크필드), 연구원이 본사와 주소가 다른 곳(주택금융연구원), 금융지주 대문과 연구소가 갈리는 곳(KB경영연구소). 테스트가 주소 깊이를 지켜봅니다.

수집기는 지우지 않았다

`research.py`의 `SITES`와 파서 열두 개는 그대로 남아 있습니다. 테스트도 돕니다. 다시 모으고 싶어지면 `python -m govpress collect-research` 한 줄이면 됩니다. 화면에서 빼는 것과 코드를 지우는 것은 다른 일입니다.

이름만 보여 주는 칩

처음에는 이름 아래 설명을 한 줄씩 달았더니 마흔세 개가 화면을 가득 메웠습니다. **이름만** 같은 너비로 줄 맞춰 깔고, 설명은 풍선말로 옮겼습니다. 묶음 제목은 크고 진하게, 묶음 사이는 넉넉히 띄웠습니다.

08 분양 — 반대로 공고 목록을 가리킨다

10월에 새로 붙인 탭입니다. 연구·업계와 같은 결 — 글을 긁지 않고 가는 길만 놓습니다. 다만 **주소가 가리키는 곳이 반대**입니다.

차례	이름	가는 곳
1	청약홈	한국부동산원 청약 통합 창구. 전국 일정이 한자리에
2	LH청약+	분양·임대 공고 목록
3	LH 공지	알려드려요 > 공지사항. 일정 변경·정정이 여기 먼저 뜸
4	SH청약	서울주택도시공사 주택분양 공고
5	GH청약	경기주택도시공사 분양·임대 공고

> **왜 대문이 아니라 목록인가**
> 연구·업계는 "그 기관이 뭘 내놓나"를 둘러보는 자리라 대문이 오래 갑니다. 분양은 "지금 뜬 공고가 뭔가"를 보러 가는 자리라 목록에 바로 닿아야 합니다. 대신 사이트가 개편되면 주소가 죽습니다. 그때는 그 줄만 고치면 됩니다. 이 까닭을 `presale.py` 맨 위에 적어 뒀습니다 — 안 그러면 나중에 "여긴 왜 이렇게 깊지" 하고 대문으로 되돌려 놓게 됩니다.

차례를 가나다순으로 두지 않았다

연구·업계 마흔세 곳은 눈으로 찾아야 하니 가나다순이 맞습니다. 분양은 다섯뿐이고 보는 순서가 따로 있습니다 — 청약홈에서 전국 일정을 보고, LH 공고를 열고, 일정이 바뀌었나 공지를 확인하고, 그다음 SH·GH. 가나다순으로 두면 GH가 맨 앞에 옵니다.

그래서 모듈이 `KEEP_WRITTEN_ORDER = True`를 선언하면 **파일에 적은 차례를 그대로** 쓰도록 했습니다. 연구·업계는 선언하지 않으므로 그대로 가나다순입니다.

긁을 수 있는지도 보긴 했다

SH·GH는 이미 보도자료를 긁고 있는 바로 그 게시판 틀이라 붙이기 쉽습니다. LH는 청약플러스가 별도 시스템이라 받아 보기 전에는 알 수 없습니다. 다만 긁는다 해도 **접수중인지 마감됐는지**는 제목·날짜만으로 알 수 없어서, 결국 눌러서 확인하게 됩니다. 바로가기 다섯 개와 견줘 얼마나 나아지는지는 아직 결론을 내지 않았습니다.

09 게시판을 붙이며 배운 것

사이트가 제각각이라고 해도, 막히는 지점은 몇 가지로 반복됐습니다. 처음 보는 게시판을 만났을 때 확인할 순서가 생겼습니다.

1. 주소가 안 바뀌는 게시판

절반쯤은 2페이지를 눌러도 주소창이 그대로입니다. 페이지 이동이 POST거나 AJAX이기 때문입니다. 처음에는 "이 사이트는 수집이 안 되겠다"고 생각했는데, **대개 같은 파라미터를 주소에 실어 GET으로 요청하면 서버가 받아 줍니다.**

기관	화면 동작	실제로 통한 요청
식품안전정보원	AJAX POST	`&pageIndex=2`
한국부동산원	숨은 양식 POST	`&currPage=2`
서울주택도시개발공사	숨은 양식 POST	`?page=2`
한국법제연구원	함수 호출	`?pageIndex=2`

그러니 주소가 안 바뀐다고 포기하지 말고, 페이지 버튼의 자바스크립트를 먼저 뜯어봅니다. 성남시처럼 정말로 안 되는 곳은 대신 한 번에 받을 건수를 늘리는 길이 있습니다.

2. 제목 링크가 자바스크립트

`javascript:`나 `#none`을 그대로 저장하면 나중에 열 수 없습니다. 함수 인자나 `data-` 속성에서 글 번호를 뽑아 상세 주소를 새로 만듭니다.

목록에 적힌 것	만들어 낸 주소
`fnTbbsView('465874')`	서울시 — `?bbsNo=158&nttNo=465874`
`main('V','415050',…)`	식품안전정보원 — `detailBBSArticle.do?nttId=…`
`data-id="116832"`	한국부동산원 — `selectNttInfo.do?nttSn=…`
`getDetailView('310068')`	서울주택도시개발공사 — `view.do?seq=…`

반대로 링크가 `href`에 잘 들어 있는 경우에도 손을 봅니다. **페이지 번호·검색 조건·세션 아이디가 잔뜩 붙어 오기 때문입니다.** "지금 3페이지를 보고 있었다"는 것은 그 글의 주소가 아니므로 떼어 냅니다.

3. 화면에 안 보이는 글자

많은 게시판이 좁은 화면용 라벨이나 새 글 아이콘을 제목 안에 숨겨 둡니다. 그냥 읽으면 제목이 "제목 실제제목"이나 "NEW 실제제목"이 됩니다. 걷어내는 목록을 공통으로 관리합니다.

```
.add-head  .mobile-tit  .only-m  .sr-only  .sr_only
.blind  .sound_only  .icoNew  .new  i:empty  img
```

4. 담당부서 칸이 없는 게시판

"날짜 앞 칸이 담당부서"라는 규칙은 부서 칸이 있는 게시판에서만 맞습니다. 없는 곳에서 그대로 적용하면 **제목이 부서로 들어갑니다.** 그래서 게시판마다 부서 칸의 유무를 명시하도록 했고, 테스트로 고정해 뒀습니다.

10 TLS — 가장 오래 붙잡은 문제

성남시와 용인시에서 수집이 실패했습니다. 브라우저로는 멀쩡히 열리는 사이트라 "차단당했나" 싶었지만, 실제로는 성격이 다른 두 문제가 겹쳐 있었습니다.

1단계 — 악수 실패

```
SSLV3_ALERT_HANDSHAKE_FAILURE
```

서버가 오래된 프로토콜·암호만 제시하는데, 요즘 OpenSSL은 기본 설정에서 그걸 거절합니다. **차단이 아니라 악수 실패입니다.** 브라우저는 하위 호환을 열어 두고 있어서 잘 열리기 때문에 오해하기 쉽습니다.

2단계 — 인증서 검증 실패

악수가 되고 나니 이번엔 다른 오류가 나왔습니다.

```
CERTIFICATE_VERIFY_FAILED
  성남시: self-signed certificate in certificate chain
  용인시: unable to get local issuer certificate
```

발급기관을 모르겠다는 뜻입니다. 국내 공공기관이 쓰는 루트 인증서는 **윈도우 인증서 저장소에는 있지만, 파이썬이 들고 다니는 목록(certifi)에는 없습니다.**

> **검증을 끄는 것은 답이 아니다**
>
> 가장 쉬운 해결은 인증서 검증을 끄는 것이지만, 그러면 중간에서 누가 가로채도 알 수 없게 됩니다. 대신 **파이썬도 운영체제 저장소를 보게** 했습니다(`truststore`). 브라우저가 신뢰하는 기관이면 여기서도 신뢰합니다 — 같은 목록을 보니까요.
>
> 실제로 이것만으로 두 사이트 다 통과했고, **검증을 끄는 단계까지 간 곳은 한 곳도 없습니다.**

결과 — 세 단계 후퇴

단계	하는 일	수집 로그 표시
1	기본 설정	없음
2	구형 TLS 허용 + OS 인증서 저장소	`(구형 TLS)`
3	인증서 검증 생략	`(인증서 검증 생략)`

설계에서 지킨 것 세 가지입니다.

- **실패한 뒤에만** 다음 단계로 갑니다. 처음부터 낮추지 않습니다.
- 성공한 단계는 **그 호스트에 대해서만** 기억합니다. 나머지 사이트는 1단계 그대로입니다.
- 어느 단계로 붙었는지 **수집 로그에 표시**합니다. 3단계가 뜨면 그 사이트만 따로 살펴보면 됩니다.

대상이 로그인도 개인정보도 없는 공개된 보도자료 목록이라는 점도 이 정도 완화를 받아들일 수 있는 근거였습니다.

덤 — 연결이 죽는 곳

성남시는 가끔 파이썬 자체가 `access violation`으로 죽었습니다. TLS 라이브러리 안에서 나는 일이라 손댈 수가 없습니다. **한 번은 새 연결로 다시 해 보고**, 그래도 안 되면 그 기관만 건너뜁니다.

11 잘못된 데이터가 쌓이지 않게

앞선 버전의 실패가 "조용히 잘못된 데이터를 쌓는" 것이었기 때문에, 이번에는 그걸 막는 장치를 여러 겹으로 뒀습니다.

저장 직전 품질 기준

- 제목, 원문 링크, 게시일, 고유 ID가 **모두** 있을 것
- 분류가 다섯 탭 중 하나일 것
- 링크가 정규화된 주소일 것 (`javascript:`, `#none` 불가)

실제 HTML로 돌리는 테스트

테스트 475개가 전부 **네트워크 없이** 돕니다. 각 사이트의 실제 목록 페이지를 저장해 둔 fixture를 대상으로 하기 때문입니다. 사이트 구조가 바뀌면 fixture를 새로 받아 교체합니다.

테스트 파일	고정해 둔 것
`test_dashboard.py`	탭 구성, 체크박스 묶음·중복, 바로가기, 시·도·구보, 외부 리소스 없음, 색 대비
`test_daily.py`	배치 파일의 모양, 받기와 수집의 분리, git 올리기 흐름
`test_local_gov.py`	지자체 8곳 파싱, 링크 정리, 광역 정렬, TLS 후퇴 순서
`test_research.py`	연구 게시판 파싱, 카드형 목록, 바로가기 목록
`test_public_org.py`	공공기관 파싱, 부서 칸 유무, 링크 조립
`test_agencies.py`	부처 코드표, 별칭 해석, 제외 목록
`test_collector.py`	korea.kr 수집 흐름, 시간 상한, 연결 재시도
`test_output_encoding.py`	결과를 파일로 넘길 때 한글이 깨지지 않을 것

"안 되는 것"을 고정하는 테스트

보통 테스트는 "이렇게 나와야 한다"를 확인하지만, 이 프로젝트에서 값진 것은 **"이렇게 나오면 안 된다"** 쪽이었습니다.

- 메뉴 링크가 기사로 섞이지 않을 것
- 게시일이 비어 있지 않을 것
- 제목에 "NEW", "새글", "제목" 같은 라벨이 붙지 않을 것
- 링크에 페이지 번호·세션 아이디가 남지 않을 것
- 같은 묶음·같은 기관이 화면에 두 번 그려지지 않을 것
- 받는 이메일 주소가 화면에 드러나지 않을 것
- 배치 파일에 한글이 한 자도 없을 것

- 딱지 색이 두 테마에서 같을 것 (한쪽에서만 안 읽히는 것을 막음)

> **이 규칙이 실제로 일한 사례**
> 화면 체크박스에서 "기타" 묶음이 두 번 그려지는 버그가 있었습니다. 분야 목록에 이미 "기타"가 있는데 뒤에 한 번 더 붙였기 때문입니다. 지자체 탭은 지역이 서울·경기뿐이라 드러나지 않다가, 공공기관을 붙이면서 보였습니다. 고친 뒤 **중복 검사 테스트 두 개를 추가**해서, 앞으로 분야를 늘리다 이름이 겹쳐도 잡히게 했습니다.

12 자동 실행과 발행

9월 판에는 "정기 실행(윈도우 작업 스케줄러)"이 남은 일로 적혀 있었습니다. 지금은 **서버PC 한 대에서 하루 세 번** 자동으로 돌고, 그 결과가 곧바로 웹사이트가 됩니다.

하루 세 번

```
09:30 · 14:00 · 17:00     작업 스케줄러 이름: PressMonitor
  수집(정부기관 · 지자체 · 공공기관)
  → 다른 PC가 올린 것 받기
  → 화면 만들기
  → git으로 올리기             2분쯤 걸립니다
```

화면 왼쪽에 적힌 "오전 9시 30분, 오후 2시, 오후 5시에 자동으로 업데이트됩니다"는 `dashboard.py`의 `UPDATE_TIMES`에서 나옵니다. **작업 스케줄러와 이 값은 반드시 같이 고쳐야 합니다.** 한쪽만 고치면 보는 사람에게는 "들어와 봤는데 안 바뀌었네"가 되고, 오류는 나지 않습니다.

GitHub Pages로 발행

처음에는 Netlify에 올렸는데 무료 사용량이 바닥나 배포가 막혔습니다. GitHub Pages로 옮겼습니다 — **main 가지의 `docs` 폴더를 그대로 사이트로 띄워 주므로**, "올리기"가 `docs`를 git에 밀어 넣는 일이 전부가 됩니다. 별도 배포 도구도, 사용량 제한도 없습니다.

자동수집.bat이 파이썬을 두 번 부르는 까닭

```
"%PY%" -u -m govpress sync            받기만 하고 끝
"%PY%" -u -m govpress daily --no-sync  새 코드로 시작
```

> **한 줄로 합치면 안 되는 이유**
>
> 파이썬은 시작할 때 필요한 파일을 한 번 읽어 머리에 담아 둡니다. 그 뒤에 git이 디스크의 파일을 바꿔 놓아도, **이미 돌고 있는 프로그램은 자기가 담아 둔 옛 내용으로 끝까지 갑니다.**
>
> 처음에는 받기를 수집과 같은 판 안에 넣었습니다. 그랬더니 10월 8일 저녁에 올린 수정이 다음 날 아침 화면에 안 나왔습니다. 받기는 분명히 성공했는데 그 판은 옛 코드로 화면을 그린 것입니다. 오류는 나지 않고, 다음 판부터는 새 코드로 돌기 때문에 하루면 저절로 맞아 버립니다. 그래서 "고친 게 왜 안 보이지" 하고 한나절을 헤매게 됩니다.
>
> 순서를 바꾸거나 한 줄로 합치면 테스트가 깨지게 해 뒀습니다.

배치 파일에 한글을 넣지 않는다

cmd는 배치 파일을 한 줄 실행할 때마다 "몇 번째 바이트까지 읽었는지"를 적어 뒀다가 되돌아옵니다. `chcp 65001`로 글자 규칙을 바꿔 놓은 채 한글(한 자에 3바이트)이 섞여 있으면 그 셈이 어긋나, 줄 한가운데로 되돌아와 **주석의 뒷토막을 명령으로 알고 실행하려 듭니다.**

```
'어디서' is not recognized as an internal or external command
```

이번에 건너뛴 것이 주석뿐이라 수집은 멀쩡했습니다. 그게 더 무섭습니다 — 어긋나는 자리는 파일을 한 줄 고칠 때마다 달라지고, 하필 `python … collect` 줄을 물면 그날 수집이 통째로 조용히 빠집니다. 그래서 배치 파일에서 한글을 전부 걷어내고, 하던 일을 파이썬으로 옮겼습니다. 테스트가 한 자도 없는지 지켜봅니다.

PC마다 다른 파이썬

서버는 가상환경의 파이썬을, 다른 PC는 PATH에 걸린 것을 씁니다. 배치 파일에 경로를 박아 두면 두 대가 같은 줄을 서로 다르게 고쳐 놓고 git에서 매번 부딪힙니다. 그래서 경로를 `python-path.txt`로 빼고, 그 파일은 git이 쳐다보지 않게 했습니다.

열어 둔 탭이 낡았는지 알려 주기

화면은 만들어질 때의 내용을 담은 파일 하나라, 탭을 열어 둔 채로는 저절로 바뀌지 않습니다. 닷새 전에 열어 둔 탭을 보고 "업데이트가 안 된다"고 여기신 일이 실제로 있었습니다.

그래서 곁에 `stamp.txt`(20바이트)를 두고, 화면이 다시 보일 때와 30분마다 그 파일을 읽어 자기가 담고 있는 시각과 견줍니다. 다르면 "새 자료가 있습니다" 띠를 띄웁니다. 새로고침은 `?t=…`를 붙여 브라우저가 가진 사본을 다시 주지 못하게 합니다.

13 화면이 커지면서 한 일

3개월치를 메우고 나니 정부기관 한 탭이 8천 줄이 됐습니다. 파일이 5MB를 넘었고, 열면 화면이 몇 초 멎었습니다.

장치	값	까닭
화면에 담는 기간	3년	그보다 오래된 것은 DB에 그대로 두고 화면에서만 뺍니다
요약 길이	120자	정부기관 본문이 화면 무게의 60%였습니다
한 번에 그리는 줄	300	나머지는 "더 보기"로 잇습니다
처음 깔리는 기간	10일	오늘 뭐가 나왔는지 보려고 여는 화면입니다

> **최근 10일의 함정**
> 목록을 최근 열흘로 자르되, **검색어나 기간을 넣는 순간 그 제한이 풀려야 합니다.** 안 그러면 "수출입 / 1월~9월"로 찾았는데 9월 것만 나옵니다. 실제로 겪은 일이고, 지금은 테스트로 못 박아 뒀습니다.
>
> "더 보기"는 상황에 따라 두 가지를 합니다 — 줄이 잘렸으면 줄을 더 그리고, 다 펼쳐졌으면 열흘씩 거슬러 올라갑니다. 지금 며칠치를 보고 있는지는 위에 최근 `10일 · 498건`처럼 적힙니다.

수집이 멎지 않게

한 지자체에서 물려 한 시간 반을 서 있다가, 작업 스케줄러의 1시간 제한에 강제 종료된 적이 있습니다. 그러면 뒤의 화면 만들기·올리기가 아예 실행되지 않습니다.

- 한 요청이 붙들 수 있는 시간을 **연결 10초 / 읽기 20초**로 나눠 잡았습니다. 숫자 하나로 주면 한 요청이 생각보다 오래 붙듭니다.

- 한 번 수집에 **10분 상한**을 뒀습니다. 이 시간이 차면 남은 기관은 다음 차례로 미루고, **그때까지 모은 것은 들고 나와** 화면을 만들고 올립니다.

14 겪은 문제와 해결

공통점이 하나 있습니다. 거의 전부 **오류 없이 틀리는** 종류였습니다.

문제	원인	해결
216건이 수집됐는데 날짜가 전부 빔	링크 글자에 '보도·뉴스·공지·자료'가 있으면 기사로 담음	구조를 읽는 파서로 다시 작성 + 메뉴 링크 배제 테스트
국무조정실이 지워도 계속 나타남	전 부처 수집에서 기사가 딸려 들어옴	수집·표시 양쪽에서 거르는 `EXCLUDED`
탭 숫자가 기사 건수였음	날마다 출렁여서 의미를 읽기 어려움	수집 대상 기관 수로 변경 ("53곳")
구리시 담당부서가 엉뚱함	송파는 4칸, 구리는 5칸인데 자리를 고정	날짜 칸을 뒤에서부터 찾고 그 앞 칸을 읽음
성남시에서 같은 글을 반복 수집	30 → 60 → 90건을 겹쳐 받음	한 번에 받는 방식으로 전환, 요청 1회
성남·용인 악수 실패	서버가 구형 TLS만 지원	구형 설정으로 재시도, 호스트별 기억
이어서 인증서 검증 실패	국내 공공기관 루트가 certifi에 없음	`truststore`로 OS 저장소 사용 (검증은 유지)
자동 수집이 두 달간 매번 죽음	결과를 파일로 넘기면 파이썬이 옛 한글 인코딩(cp949)으로 쓰려 드는데, 안내문의 '—' 한 글자를 못 써서 그 자리에서 멈춤	진입점에서 출력을 UTF-8로 못박음 + 회귀 테스트
Netlify 배포가 막힘	무료 사용량 소진 (인증 문제로 보였음)	GitHub Pages로 이전 — `docs` 폴더가 곧 사이트
수집은 멀쩡한데 화면이 안 바뀜	새 PC의 git에 작성자 이름·이메일이 없어 올리기만 빠짐	한 번 설정 + 그 오류를 한글로 알려주도록
고친 것이 하루 늦게 나타남	받기를 수집과 같은 판에서 해서, 받아 온 코드가 그 판에 안 쓰임	받기를 별도의 파이썬 호출로 분리
배치 파일이 주석을 명령으로 읽음	UTF-8 한글 + `chcp 65001`에서 cmd의 바이트 셈이 어긋남	배치에서 한글 제거, 일은 파이썬으로
수집이 한 시간 반 멎음	한 지자체에서 물림 → 스케줄러 1시간 제한에 강제 종료	요청 시간 상한 + 한 판 10분 상한, 모은 것은 들고 나옴
기간을 넣었는데 9월 것만 나옴	최근 10일 제한이 검색에도 걸림	검색어·기간이 있으면 제한 해제 + 테스트
닷새 전 탭을 보고 "갱신이 안 된다"	화면은 파일 하나라 열어 둔 채로는 안 바뀜	`stamp.txt`와 낡음 알림 띠
집·사무실 작업이 안 이어짐	파일이 한 PC에만 있음	GitHub로 동기화 (구글 드라이브 대신)

> **cp949 사고가 남긴 것**
>
> 가장 비쌌던 실패입니다. 자동 수집이 하루 세 번 돌면서 **매번 첫 줄에서 죽었는데**, 화면은 예전 자료로 계속 다시 만들어지니 겉으로는 멀쩡해 보였습니다. 두 달 가까이 모르고 지났습니다.
>
> 이 일로 두 가지가 규칙이 됐습니다. 첫째, **결과를 파일로 넘길 때도 출력 인코딩을 명시**한다. 둘째, **"성공했다"는 겉모습을 믿지 말고 기록의 끝을 본다.**

15 명령어 요약

```
# 목록 확인
python -m govpress depts        # 정부부처 53곳
python -m govpress locals       # 지자체
python -m govpress publics      # 공공기관
python -m govpress labs         # 연구소 (수집기 목록)

# 수집
python -m govpress collect --dept 국토교통부 --from 26.08.01 --to 26.09.09
python -m govpress collect --days 7
python -m govpress collect-local    --pages 3
python -m govpress collect-public   --pages 3
python -m govpress collect-research --pages 3   # 지금은 자동 실행에서 뺌

# 화면
python -m govpress dashboard --open   # dashboard.html 만들어 열기
python -m govpress publish            # docs 폴더(=웹사이트) 만들기

# 하루치 한 판 (자동수집.bat이 부르는 것)
python -m govpress sync               # 받기만
python -m govpress daily --no-sync    # 수집 → 화면 → 올리기

# 코드를 고쳐 올릴 때
python -m pytest -q
python -m govpress release "무엇을 고쳤는지"
```

16 남은 일

확인할 것

- **바로가기 48곳을 한 번씩 눌러 보기.** 분양 5곳과 시·도·구보 8곳은 사이트가 로봇 접근을 막아 둬서 자동으로는 확인할 수 없었습니다.

해 볼 만한 것

- **지자체 고시·공고를 목록으로.** 시보·도보 말고 지자체별 고시·공고 게시판(서울 `news_notice.do`, 경기 `bsIdx=469`, 성남 `pm010301`)은 개별 건이 제목으로 늘어섭니다. 부동산 쪽에서는 지구단위계획·용도지역 변경이 여기 뜹니다. 긁을 수 있을지 아직 안 봤습니다.
- **서울 도시관리계획안 열람공고** (`urban.seoul.go.kr`) 와 **경기 부동산 관련 공고** — 메뉴를 훑다 눈에 띈 곳입니다.

- **분양 공고를 긁을지.** SH·GH는 이미 쓰는 게시판 틀이라 쉽습니다. LH는 받아 봐야 알고, 긁어도 접수중·마감 여부는 알 수 없습니다.
- **키워드 알림** (메일 또는 슬랙) — 9월 판부터 남아 있는 항목입니다.

기관 추가

기관 목록은 구글 시트로 주고받고 있습니다. 필요한 칸은 **기관명 · 묶음 · 보도자료 1페이지 주소** 셋입니다. 2페이지 주소는 처음엔 받았지만, 절반쯤은 주소가 안 바뀌고 페이지 버튼을 직접 뜯어보는 편이 빠르고 정확해서 이제 받지 않습니다.

새 기관을 붙이는 순서

1. 보도자료 목록 페이지를 열어 실제 HTML을 확인합니다.
2. 목록 부분을 `tests/fixtures/`에 저장합니다.
3. 파서를 쓰고 테스트를 먼저 통과시킵니다.
4. 페이지 버튼의 자바스크립트를 뜯어 페이지 파라미터를 찾습니다.
5. `SITES`에 한 줄 추가합니다.

순서를 지키면 조용히 잘못된 데이터가 쌓이는 일은 생기지 않습니다. 이 프로젝트에서 가장 값진 규칙입니다.

바로가기를 고치는 순서

연구·업계와 분양은 구글 시트의 주소를 고친 뒤 그 모듈의 한 줄만 바꾸면 됩니다. 시·도·구보는 `local_gov.py`의 `GAZETTES`입니다. 기관 이름을 잘못 적으면 바로가기가 그냥 안 붙고 오류도 안 나므로, 이름이 실제 기관과 맞는지 테스트가 확인합니다.