

작업 기록

# 보도자료 모니터

정부기관·지자체·공공기관·연구소 보도자료 수집기

---

|       |                                                                                                                   |
|-------|-------------------------------------------------------------------------------------------------------------------|
| 작성일   | 2026년 9월 9일                                                                                                       |
| 저장소   | <a href="https://github.com/kwakmg74-michael/gov-press-monitor">github.com/kwakmg74-michael/gov-press-monitor</a> |
| 현재 상태 | 69개 기관 / 게시판 70개 / 테스트 247개 통과                                                                                    |
| 실행 환경 | Python 3, 사무실 PC(pc1)와 집 양쪽에서 Git으로 동기화                                                                           |

## 01 한눈에 보기

보도자료를 매일 자동으로 모아, 기관·기간·검색어로 좁혀 볼 수 있는 웹 대시보드를 만드는 도구입니다. 대시보드는 외부 리소스를 전혀 불러오지 않는 HTML 파일 하나로 떨어져서, 더블클릭으로 열리고 공유 폴더에 그대로 올려도 동작합니다.

수집 대상 기관

**69곳**

게시판 기준으로 70개

테스트

**247개**

네트워크 없이 전부 통과

### 네 개의 탭

| 탭    | 기관 | 게시판 | 수집 방식                   | 상태   |
|------|----|-----|-------------------------|------|
| 정부기관 | 53 | 1   | korea.kr 통합 창구 하나로 전 부처 | 완료   |
| 지자체  | 8  | 8   | 사이트별 어댑터 (서울 3, 경기 5)   | 완료   |
| 공공기관 | 6  | 7   | 사이트별 어댑터                | 확장 중 |
| 연구소  | 2  | 2   | 사이트별 어댑터                | 확장 중 |

탭에 붙는 숫자는 **기사 건수가 아니라 수집 대상 기관 수**입니다. 기사 건수는 날마다 출렁이지만 '몇 곳을 훑고 있는가'는 그 탭이 무엇을 덮는지 말해 주기 때문입니다. 그날 표시되는 건수는 목록 위에 따로 나옵니다.

### 대시보드가 하는 일

- 기관 체크박스 — 묶음(정부기관은 부·처/청/위원회, 지자체는 지역, 나머지는 분야)별로 나뉘고 묶음 안은 가나다순. 그날 발표가 없던 기관도 항상 목록에 나옵니다(건수 0은 흐리게).
- 검색 기간 — YY.MM.DD ~ YY.MM.DD 직접 입력 + 오늘·7일·30일·전체 버튼
- 검색어 — 제목·요약·기관에서 찾고 결과에서 하이라이트
- 목록 — 제목 / 기관 · 날짜 · 담당부서가 한 줄에. 제목을 누르면 원문이 새 탭에서 열립니다.

### 결과물

| 파일             | 내용                                                      |
|----------------|---------------------------------------------------------|
| articles.db    | SQLite. (source, uid) 기준으로 중복 저장되지 않으므로 매일 돌려도 계속 쌓입니다. |
| dashboard.html | 외부 리소스를 전혀 불러오지 않는 파일 하나. 오프라인·사내망에서도 열립니다.             |

## 02 왜 처음부터 다시 만들었나

이 프로젝트에는 앞선 버전이 있었습니다. 돌아가긴 했는데 결과물이 이상했고, "느낌이 별로"라는 것이 다시 시작하게 된 계기였습니다. 코드를 열어 보니 그 느낌에는 분명한 근거가 있었습니다.

## 증상

| 무엇이   | 어떻게 나왔나                             |
|-------|-------------------------------------|
| 수집 건수 | 216건 — 실제 보도자료보다 훨씬 많음              |
| 게시일   | 전부 비어 있음                            |
| 제목    | "보도자료", "공지사항" 같은 메뉴 이름이 기사로 섞여 들어옴 |

## 원인

파서가 페이지 안의 모든 링크를 훑으면서, 링크 글자에 `보도 · 뉴스 · 공지 · 자료` 중 하나라도 들어 있으면 기사로 담고 있었습니다. 그러니 왼쪽 메뉴의 "보도자료" 링크도, 하단 배너의 "자료실"도 전부 기사가 됐습니다. 목록의 구조를 보는 게 아니라 글자를 보고 있었던 겁니다.

### 이런 실패가 위험한 이유

오류가 나지 않습니다. 조용히 잘못된 데이터를 쌓습니다. 216건이라는 숫자만 보면 잘 돌아가는 것처럼 보이고, 날짜가 비었다는 걸 알아차리려면 목록을 직접 들여다봐야 합니다. 그래서 이번에는 **"무엇이 들어오면 안 되는가"를 테스트로 먼저 고정했습니다.**

## 다시 만들 때 세운 기준

1. **파싱과 네트워크를 분리한다.** 목록 HTML을 받아 결과 목록으로 바꾸는 함수는 순수 함수로 두고, 받아 오는 일은 따로 분리합니다. 그래야 저장해 둔 HTML로 네트워크 없이 테스트할 수 있습니다.
2. **실제 페이지를 저장해 fixture로 쓴다.** 만들어 낸 예시가 아니라 그 사이트에서 실제로 받은 HTML을 `tests/fixtures/`에 넣고 그걸 대상으로 테스트합니다.
3. **구조를 확인하지 않은 기관은 목록에 넣지 않는다.** 짐작해서 쓴 파서는 조용히 실패하기 때문에, 확인 전에는 `PENDING`에만 적어 둡니다.
4. **품질 기준을 저장 직전에 건다.** 제목·링크·게시일·고유 ID가 하나라도 비면 버립니다.

이 네 가지가 이후 모든 작업의 뼈대가 됐습니다. 기관을 하나 붙일 때마다 "실제 HTML 저장 → 파서 작성 → 테스트 통과 → 목록에 등록" 순서를 지켰습니다.

## 03 전체 구조



| 파일            | 줄   | 역할                                        |
|---------------|-----|-------------------------------------------|
| models.py     | 113 | Article 모델, 네 개 분류(탭) 정의, 날짜·텍스트 정규화      |
| boards.py     | 401 | 게시판 수집 공통 뼈대 — Site, 받아 오기, TLS 후퇴, 중복 제거 |
| korea_kr.py   | 293 | korea.kr 목록 파싱과 페이지 순회 (정부기관 전용)          |
| local_gov.py  | 531 | 지자체 8곳 어댑터, 지역 묶음                         |
| public_org.py | 361 | 공공기관 6곳 어댑터, 분야 묶음                        |
| research.py   | 199 | 연구소 2곳 어댑터                                |
| agencies.py   | —   | 정부부처 코드표 53곳, 조직도 기준 구분·소속, 줄임말 해석        |
| storage.py    | 173 | SQLite 저장, 중복 제거, 조회                      |
| dashboard.py  | 719 | 단일 HTML 대시보드 생성                           |
| __main__.py   | —   | 명령줄 진입점                                   |

## boards.py를 따로 뺀 이유

처음에는 지자체 수집기 하나뿐이라 모든 게 `local_gov.py` 안에 있었습니다. 공공기관·연구소를 붙이면서 **세 모듈이 필요로 하는 일이 완전히 같다**는 게 분명해졌습니다 — 목록 주소를 만들고, 받아 오고, 파서에 넘기고, 저장 형식으로 바꾼다.

그래서 공통분모를 `boards.py` 로 뽑았습니다. 각 분류 모듈은 이제 **자기 파서와 기관 목록만** 갖습니다. TLS 처리를 고치면 세 곳에 한꺼번에 반영되고, 새 분류를 붙일 때 베껴 쓸 코드가 거의 없습니다.

## Article — 모든 수집기의 공통 출력

```
Article(
    source,          # 출처 열쇠 (local:서울시, public:금융감독원 ...)
    uid,             # 그 출처 안에서 고유한 글 번호
    agency,          # 화면에 뜨는 기관 이름
    title, link, published_at,
    summary,         # 담당부서 또는 요약
    category,        # 정부기관 / 지자체 / 공공기관 / 연구소
)
```

수집기가 무엇이든 이 형태로만 넘기면 저장·중복제거·탭 배치가 자동으로 됩니다. `(source, uid)` 가 중복 방지의 열쇠라서, 기관끼리 글 번호가 겹쳐도 안전합니다.

## 04 정부기관 — 통합 창구를 찾은 것이 컸다

부처가 53곳이니 어댑터도 53개가 필요할 거라 생각하기 쉽습니다. 그런데 **대한민국 정책브리핑(korea.kr)**이 전 부처 보도자료를 한곳에 모아 제공하고 있었습니다. 어댑터 하나로 53곳을 덮습니다.

### 목록 단계에서 필요한 게 다 채워진다

korea.kr 목록에는 제목·부처·게시일·원문 링크가 모두 들어 있습니다. 상세 페이지를 따로 열 필요가 없어서 요청 수가 크게 줄었습니다.

## 서버가 걸러 준다

더 중요한 발견은 **부처·기간·검색어를 서버에서 걸러 준다**는 점이었습니다. 다 받아 온 뒤 버리는 게 아니라 필요한 것만 요청하므로 훨씬 빠르고 사이트에도 부담이 적습니다.

| 파라미터                | 거르는 기준                      |
|---------------------|-----------------------------|
| repCode             | 발행 부처 (54개 코드를 조직도 기준으로 정리) |
| srchWord            | 검색어                         |
| startDate / endDate | 기간                          |
| pageIndex           | 페이지                         |

## 기관 이름은 정부 조직도를 기준으로

조직 개편으로 이름이 바뀐 기관이 많아서, 옛 이름이나 줄임말로 입력해도 찾아가도록 별칭을 정리했습니다.

| 입력              | 찾아가는 기관 |
|-----------------|---------|
| 특허청             | 지식재산처   |
| 통계청             | 국가데이터처  |
| 문화재청            | 국가유산청   |
| 산업통상자원부         | 산업통상부   |
| 여성가족부           | 성평등가족부  |
| 국토부 · 금융위 · 식약처 | 각 정식 명칭 |

여러 기관으로 나뉜 경우에는 어디로 갔는지 알려 줍니다.

```
$ python -m govpress collect --dept 기획재정부
오류: 기획재정부는 기획예산처와 재정경제부로 나뉘었습니다.
후속 기관 이름으로 지정하세요.
```

### 제외 목록

국무조정실은 목록에서 뺐는데, 전 부처를 훑을 때 기사가 딸려 들어와 계속 다시 나타났습니다. 그래서 **수집 단계와 표시 단계 양쪽에서** 거르도록 EXCLUDED 를 뒀습니다. 한쪽만 막으면 다른 쪽으로 새어 나옵니다.

조직도에는 있지만 korea.kr이 보도자료를 제공하지 않는 기관(국가정보원, 고위공직자범죄수사처, 국가교육위원회 등)은 코드표에 없어 수집 대상이 아닙니다. 한국소비자원·금융감독원 같은 공공기관도 korea.kr에는 발행 기관으로 나오지 않아, 별도 수집기에서 다룹니다.

## 05 지자체 — 통합 창구가 없다

지자체에는 korea.kr 같은 통합 창구가 없습니다. 사이트마다 게시판 소프트웨어가 달라서 어댑터가 하나씩 필요합니다. 우선 8곳을 붙였습니다.

| 지역 | 기관  | 파서                   | 페이지 파라미터           |
|----|-----|----------------------|--------------------|
| 서울 | 서울시 | parse_seoul          | curPage            |
|    | 강동구 | parse_gangdong       | cp                 |
|    | 송파구 | parse_standard_board | pageIndex          |
| 경기 | 경기도 | parse_gyeonggi       | page               |
|    | 구리시 | parse_standard_board | pageIndex          |
|    | 성남시 | parse_seongnam       | cntPerPage (건수 방식) |
|    | 용인시 | parse_yongin         | q_currPage         |
|    | 하남시 | parse_card_board     | pageIndex          |

8곳에 게시판 종류가 넷, 페이지 파라미터가 다섯 가지였습니다. 이 제각각을 파악하는 데 시간이 제일 많이 들었습니다.

## 정렬 — 광역이 먼저

처음에는 지역 안을 가나다순으로만 정렬해서 서울 묶음이 "강동구 · 서울시 · 송파구"로 나왔습니다. 광역자치단체가 가운데 끼어 있으니 눈에 안 들어옵니다. **광역을 맨 앞에 고정**하도록 바꿨습니다.

```
서울  서울시  강동구  송파구
경기  경기도  구리시  성남시  용인시  하남시
```

이름을 코드에 박아 넣는 대신 `metro=True` 표시를 뒀습니다. 나중에 인천·부산을 넣을 때 그 지역 광역 한 곳에만 붙이면 같은 순서가 됩니다.

## 담당부서 칸 찾기 — 자리를 고정하지 않는다

송파구와 구리시는 같은 행정표준 게시판인데도 칸 수가 달랐습니다. 송파는 4칸, 구리는 '파일' 칸이 끼어 5칸입니다. 담당부서를 세 번째 칸으로 고정해 뒀더니 구리시에서 엉뚱한 값이 들어왔습니다.

### 해결 방식

자리를 세는 대신 **뒤에서부터 날짜처럼 보이는 칸을 찾고, 그 바로 앞 칸을 담당부서로 봅니다.** 칸이 하나 늘거나 줄어도 견딥니다. 이 방식은 나중에 공공기관·연구소에서도 그대로 통했습니다.

## 성남시 — 페이지를 넘길 수 없는 게시판

성남시는 페이지 이동이 POST로만 됩니다. 주소로는 2페이지를 요청할 방법이 없었습니다. 대신 `cntPerPage` 로 **한 번에 받을 건수를 늘릴 수** 있었습니다. 그래서 이 사이트만 "페이지를 넘기는" 대신 "한 번에 많이 받는" 방식( `page_mode="size"` ) 으로 처리합니다.

처음에는 이걸 모르고 30건 → 60건 → 90건을 겹쳐 받아, 같은 글을 세 번씩 다시 읽고 있었습니다. 지금은 한 번만 요청합니다.

## 제외한 곳

남양주시는 개발자도구 감지 페이지가 떠서 정상 목록을 받을 수 없었습니다. 목록에 넣지 않았습니다.

## 06 공공기관과 연구소

지자체와 사정이 같습니다 — 전국 단위 통합 창구가 없어 기관마다 어댑터가 필요합니다. 다만 붙여 보니 **지자체보다 훨씬 고릅니다**. 상당수가 정부 표준 CMS를 쓰기 때문입니다.

### 공공기관 6곳 / 게시판 7개

| 분야  | 기관         | 페이지 파라미터  | 비고       |
|-----|------------|-----------|----------|
| 부동산 | 서울주택도시개발공사 | page      | 보도자료 게시판 |
|     | 서울주택도시개발공사 | page      | 해명자료 게시판 |
|     | 한국부동산원     | currPage  |          |
|     | 한국산업단지공단   | pageIndex |          |
| 금융  | 금융감독원      | pageIndex | 담당부서 있음  |
| 기타  | 식품안전정보원    | pageIndex |          |
|     | 한국소비자원     | page      | 담당부서 있음  |

### 연구소 2곳

| 분야  | 기관      | 페이지 파라미터 | 목록 형태   |
|-----|---------|----------|---------|
| 부동산 | 국토연구원   | nPage    | 표 게시판   |
| 기타  | 건축공간연구원 | nPage    | 발간물 카드형 |

연구기관은 보도자료보다 **발간물(연구보고서)** 쪽이 많아서 목록이 게시판이 아니라 카드형인 곳이 있습니다. 그래도 뽑는 것은 같습니다 — 제목·날짜·원문 링크.

#### 숫자로 본 차이

지자체 8곳 → 게시판 4종, 페이지 파라미터 5가지

공공기관·연구소 9개 게시판 → 페이지 파라미터 **4가지** ( pageIndex · nPage · page · currPage )

남은 기관들도 비슷한 속도로 붙을 것으로 봅니다.

### 한 기관에 게시판이 여럿일 때

서울주택도시개발공사는 보도자료와 해명자료가 따로 있고, KB경영연구소는 게시판이 셋입니다. 문제는 기관 이름이 두 가지 일을 겸하고 있었다는 점입니다 — 화면에 보이는 이름이자, 중복 저장을 막는 열쇠. 게시판이 셋이면 열쇠가 겹쳐 서로를 덮어 씹습니다.

열쇠를 게시판 단위로, 이름을 기관 단위로 나눠서 해결했습니다.

```
_site("서울주택도시개발공사", "부동산", "...m_139/list.do", "page",  
      parse_sh, board="보도자료"),  
_site("서울주택도시개발공사", "부동산", "...m_612/list.do", "page",  
      parse_sh, board="해명자료"),
```

저장 열쇠( source )만 갈라지고, 화면에는 기관 이름 하나로 나오며 결과는 날짜순으로 섞입니다. 체크박스도 하나고, 탭 숫자도 한 곳으로 썩니다.

## 07 게시판 17개를 붙이며 배운 것

사이트가 제각각이라고 해도, 막히는 지점은 몇 가지로 반복됐습니다. 처음 보는 게시판을 만났을 때 확인할 순서가 생겼습니다.

### 1. 주소가 안 바뀌는 게시판

절반쯤은 2페이지를 눌러도 주소창이 그대로입니다. 페이지 이동이 POST거나 AJAX이기 때문입니다. 처음에는 "이 사이트는 수집이 안 되겠다"고 생각했는데, 대개 같은 파라미터를 주소에 실어 GET으로 요청하면 서버가 받아 줍니다.

| 기관         | 화면 동작      | 실제로 통한 요청                     |
|------------|------------|-------------------------------|
| 식품안전정보원    | AJAX POST  | <code>&amp;pageIndex=2</code> |
| 한국부동산원     | 숨은 양식 POST | <code>&amp;currPage=2</code>  |
| 서울주택도시개발공사 | 숨은 양식 POST | <code>?page=2</code>          |
| 한국법제연구원    | 함수 호출      | <code>?pageIndex=2</code>     |

그러니 주소가 안 바뀐다고 포기하지 말고, 페이지 버튼의 자바스크립트를 먼저 뜯어봅니다. 성남시처럼 정말로 안 되는 곳은 대신 한 번에 받을 건수를 늘리는 길이 있습니다.

### 2. 제목 링크가 자바스크립트

javascript: 나 #none 을 그대로 저장하면 나중에 열 수 없습니다. 함수 인자나 data- 속성에서 글 번호를 뽑아 상세 주소를 새로 만듭니다.

| 목록에 적힌 것                              | 만들어 낸 주소                                             |
|---------------------------------------|------------------------------------------------------|
| <code>fnTbbsView('465874')</code>     | 서울시 — <code>?bbsNo=158&amp;nttNo=465874</code>       |
| <code>main('V', '415050', ...)</code> | 식품안전정보원 — <code>detailBBSArticle.do?nttId=...</code> |
| <code>data-id="116832"</code>         | 한국부동산원 — <code>selectNttInfo.do?nttSn=...</code>     |
| <code>getDetailView('310068')</code>  | 서울주택도시개발공사 — <code>view.do?seq=...</code>            |
| <code>bbsArticleDet('49636')</code>   | 한국산업단지공단 — <code>/boardDetail/1103?bbsSeq=...</code> |

반대로 링크가 href에 잘 들어 있는 경우에도 손을 봅니다. 페이지 번호·검색 조건·세션 아이디가 잔뜩 붙어 오기 때문입니다. "지금 3페이지를 보고 있었다"는 것은 그 글의 주소가 아니므로 떼어 냅니다.

### 3. 화면에 안 보이는 글자

많은 게시판이 좁은 화면용 라벨이나 새 글 아이콘을 제목 안에 숨겨 둡니다. 그냥 읽으면 제목이 "제목 실제제목"이나 "NEW 실제제목"이 됩니다. 건어내는 목록을 공통으로 관리합니다.

```
.add-head .mobile-tit .only-m .sr-only .sr_only  
.blind .sound_only .icoNew .new i:empty img
```

#### 4. 담당부서 칸이 없는 게시판

"날짜 앞 칸이 담당부서"라는 규칙은 부서 칸이 있는 게시판에서만 맞습니다. 없는 곳에서 그대로 적용하면 **제목이 부서로 들어갑니다**. 그래서 게시판마다 부서 칸의 유무를 명시하도록 했고, 테스트로 고정해 뒀습니다.

## 08 TLS — 가장 오래 붙잡은 문제

성남시와 용인시에서 수집이 실패했습니다. 브라우저로는 멀쩡히 열리는 사이트라 "차단당했나" 싶었지만, 실제로는 성격이 다른 두 문제가 겹쳐 있었습니다.

### 1단계 — 악수 실패

```
SSLV3_ALERT_HANDSHAKE_FAILURE
```

서버가 오래된 프로토콜·암호만 제시하는데, 요즘 OpenSSL은 기본 설정에서 그걸 거절합니다. **차단이 아니라 악수 실패입니다**. 브라우저는 하위 호환을 열어 두고 있어서 잘 열리기 때문에 오해하기 쉽습니다.

우리 쪽이 받아들이는 범위를 넓히면 붙습니다.

### 2단계 — 인증서 검증 실패

악수가 되고 나니 이번엔 다른 오류가 나왔습니다.

```
CERTIFICATE_VERIFY_FAILED  
성남시: self-signed certificate in certificate chain  
용인시: unable to get local issuer certificate
```

발급기관을 모르겠다는 뜻입니다. 국내 공공기관이 쓰는 루트 인증서는 윈도우 인증서 저장소에는 있지만, 파이썬이 들고 다니는 목록(certifi)에는 없습니다.

#### 검증을 끄는 것은 답이 아니다

가장 쉬운 해결은 인증서 검증을 끄는 것이지만, 그러면 중간에서 누가 가로채도 알 수 없게 됩니다. 대신 **파이썬도 운영 체제 저장소를 보게** 했습니다( truststore ). 브라우저가 신뢰하는 기관이면 여기서도 신뢰합니다 — 같은 목록을 보니까요.

실제로 이것만으로 두 사이트 다 통과했고, 검증을 끄는 단계까지 간 곳은 **한 곳도 없었습니다**.

### 결과 — 세 단계 후퇴

| 단계 | 하는 일                   | 수집 로그 표시    |
|----|------------------------|-------------|
| 1  | 기본 설정                  | 없음          |
| 2  | 구형 TLS 허용 + OS 인증서 저장소 | (구형 TLS)    |
| 3  | 인증서 검증 생략              | (인증서 검증 생략) |

설계에서 지킨 것 세 가지입니다.

- **실패한 뒤에만** 다음 단계로 갑니다. 처음부터 낮추지 않습니다.
- 성공한 단계는 **그 호스트에 대해서만** 기억합니다. 나머지 사이트는 1단계 그대로입니다.
- 어느 단계로 붙었는지 **수집 로그에 표시**합니다. 3단계가 뜨면 그 사이트만 따로 살펴보면 됩니다.

대상이 로그인도 개인정보도 없는 공개된 보도자료 목록이라는 점도 이 정도 완화를 받아들일 수 있는 근거였습니다.

[성남시] 1페이지 → 60건 (구형 TLS)  
[용인시] 1페이지 → 10건 (구형 TLS)  
[하남시] 1페이지 → 10건

## 09 잘못된 데이터가 쌓이지 않게

앞선 버전의 실패가 "조용히 잘못된 데이터를 쌓는" 것이었기 때문에, 이번에는 그걸 막는 장치를 여러 겹으로 뒀습니다.

### 저장 직전 품질 기준

다음은 만족하지 못하는 항목은 버립니다.

- 제목, 원문 링크, 게시일, 고유 ID가 **모두** 있을 것
- 분류가 네 개 탭 중 하나일 것
- 링크가 정규화된 주소일 것 ( `javascript:` , `#none` 불가)

### 실제 HTML로 돌리는 테스트

테스트 247개가 전부 **네트워크 없이** 돛니다. 각 사이트의 실제 목록 페이지를 저장해 둔 fixture 17개를 대상으로 하기 때문입니다. 사이트 구조가 바뀌면 fixture를 새로 받아 교체합니다.

| 테스트 파일                          | 줄   | 고정해 둔 것                            |
|---------------------------------|-----|------------------------------------|
| <code>test_local_gov.py</code>  | 406 | 지자체 8곳 파싱, 링크 정리, 광역 정렬, TLS 후퇴 순서 |
| <code>test_public_org.py</code> | 201 | 공공기관 6곳 파싱, 부서 칸 유무, 링크 조립         |
| <code>test_dashboard.py</code>  | 198 | 탭 구성, 체크박스 묶음·중복, 외부 리소스 없음        |
| <code>test_agencies.py</code>   | 171 | 부처 코드표, 별칭 해석, 제외 목록               |
| <code>test_collector.py</code>  | 171 | korea.kr 수집 흐름                     |
| <code>test_storage.py</code>    | 150 | 중복 제거, 스키마 이전                      |
| <code>test_korea_kr.py</code>   | 143 | 목록 파싱, 메뉴 링크가 안 섞이는지               |
| <code>test_research.py</code>   | 134 | 연구소 2곳 파싱, 카드형 목록                  |

### "안 되는 것"을 고정하는 테스트

보통 테스트는 "이렇게 나와야 한다"를 확인하지만, 이 프로젝트에서 값진 것은 "이렇게 나오면 안 된다" 쪽이었습니다.

- 메뉴 링크가 기사로 섞이지 않을 것

- 게시일이 비어 있지 않을 것
- 제목에 "NEW", "새글", "제목" 같은 라벨이 붙지 않을 것
- 링크에 페이지 번호·세션 아이디가 남지 않을 것
- 부서 칸이 없는 게시판에서 제목이 부서로 들어가지 않을 것
- 같은 묶음·같은 기관이 화면에 두 번 그려지지 않을 것

### 확인하지 않은 기관은 넣지 않는다

구조를 보지 않고 짐작해서 쓴 파서는 조용히 메뉴 링크를 주워 담거나 빈 결과를 냅니다. 알아채기가 어렵습니다. 그래서 확인 전에는 `PENDING`에만 적어 두고, 목록과 대기 명단이 겹치지 않는지도 테스트로 확인합니다.

#### 이 규칙이 실제로 일한 사례

대시보드 체크박스에서 "기타" 묶음이 두 번 그려지는 버그가 있었습니다. 분야 목록에 이미 "기타"가 있는데 뒤에 한 번 더 붙었기 때문입니다. 지자체 탭은 지역이 서울·경기뿐이라 드러나지 않다가, 공공기관을 붙이면서 보였습니다. 고친 뒤 **중복 검사 테스트 두 개를 추가**해서, 앞으로 분야를 늘리다 이름이 겹쳐도 잡히게 했습니다.

## 10 겪은 문제와 해결

| 문제                   | 원인                               | 해결                                           |
|----------------------|----------------------------------|----------------------------------------------|
| 216건이 수집됐는데 날짜가 전부 빈 | 링크 글자에 '보도·뉴스·공지·자료'가 있으면 기사로 담음 | korea.kr 구조를 읽는 파서로 다시 작성 + 메뉴 링크 배제 테스트     |
| 국무조정실이 지워도 계속 나타남    | 전 부처 수집에서 기사가 딸려 들어옴             | 수집·표시 양쪽에서 거르는 <code>EXCLUDED</code>         |
| 체크박스에 수집된 기관만 나옴     | 데이터에 등장한 기관으로 목록을 만들             | 코드표 전체 명단을 항상 표시, 건수 0은 흐리게                  |
| 탭 숫자가 기사 건수였음        | 날마다 출령여서 의미를 읽기 어려움              | 수집 대상 기관 수로 변경 ("53곳")                       |
| 목록이 세로로 너무 김         | 기관·날짜·부서가 각각 줄을 차지               | 한 줄로 합침. 항목 높이 100px → 72px                  |
| 구리시 담당부서가 엉뚱함        | 송파는 4칸, 구리는 5칸인데 자리를 고정          | 날짜 칸을 뒤에서부터 찾고 그 앞 칸을 읽음                     |
| 성남시에서 같은 글을 반복 수집    | 30 → 60 → 90건을 겹쳐 받음             | 한 번에 받는 방식으로 전환, 요청 1회                       |
| 성남·용인 악수 실패          | 서버가 구형 TLS만 지원                   | 구형 설정으로 재시도, 호스트별 기억                         |
| 이어서 인증서 검증 실패        | 국내 공공기관 루트가 certifi에 없음          | <code>truststore</code> 로 OS 저장소 사용 (검증은 유지) |
| 체크박스 "기타"가 두 번 나옴    | 분야 목록에 이미 있는데 뒤에 또 붙임            | 중복 제거 + 중복 검사 테스트 2개                         |
| 대시보드 자바스크립트가 깨짐      | 파이썬 문자열이 정규식의 역슬래시를 먹음           | 템플릿을 raw 문자열로                                |
| 집·사무실 작업이 안 이어짐      | 파일이 한 PC에만 있음                    | GitHub로 동기화 (구글 드라이브 대신)                     |

## Git을 고른 이유

구글 드라이브도 후보였지만, 코드는 Git 쪽이 맞습니다. 어떤 변경이 왜 들어갔는지 남고, 잘못 고쳤을 때 되돌릴 수 있으며, 양쪽에서 동시에 건드려도 충돌을 알려 줍니다. 드라이브는 나중 파일이 앞 파일을 그냥 덮어씁니다.

### 집에서 이어받을 때

git pull 뒤에 pip install truststore 도 한 번 해 주셔야 합니다. 코드가 아니라 패키지라서 따라오지 않습니다.

## 11 명령어 요약

```
# 목록 확인
python -m govpress depts      # 정부부처 53곳
python -m govpress locals     # 지자체
python -m govpress publics    # 공공기관
python -m govpress labs       # 연구소

# 수집
python -m govpress collect --dept 국토교통부 --from 26.08.01 --to 26.09.09
python -m govpress collect --days 7
python -m govpress collect-local --pages 2
python -m govpress collect-public --pages 2
python -m govpress collect-research --pages 2

# 대시보드
python -m govpress dashboard --open

# 테스트
python -m pytest -q
```

## 12 남은 일

### 기관 추가

| 분류          | 대기 중인 기관                                                                  |
|-------------|---------------------------------------------------------------------------|
| 공공기관 7<br>곳 | 한국인터넷진흥원, 한국자산관리공사, 한국저작권보호원, 한국저작권위원회, 한국주택금융공사, 한국지식재산보호<br>원, 한국토지주택공사 |
| 연구소 6곳      | KB경영연구소(게시판 3개), 한국법제연구원, 한국조세재정연구원, 한국행정연구원, 한국개발연구원, 한국지식재산<br>연구원      |

기관 목록은 구글 시트로 주고받고 있습니다. 필요한 칸은 **기관명 · 묶음 · 보도자료 1페이지 주소** 셋입니다. 2페이지 주소는 처음엔 받았지만, 절반쯤은 주소가 안 바뀌고 페이지 버튼을 직접 뜯어보는 편이 빠르고 정확해서 이제 받지 않습니다.

### 기능

- 키워드 알림 (메일 또는 슬랙)
- 정기 실행 (윈도우 작업 스케줄러)

- 사무실 홈페이지 연동 — 대시보드에서 체크한 항목만 홈페이지에 띄우는 구상. 홈페이지가 아직 없어 보류 중입니다.

## 새 기관을 붙이는 순서

1. 보도자료 목록 페이지를 열어 실제 HTML을 확인합니다.
2. 목록 부분을 `tests/fixtures/` 에 저장합니다.
3. 파서를 쓰고 테스트를 먼저 통과시킵니다.
4. 페이지 버튼의 자바스크립트를 뜯어 페이지 파라미터를 찾습니다.
5. `SITES` 에 한 줄 추가합니다.

순서를 지키면 조용히 잘못된 데이터가 쌓이는 일은 생기지 않습니다. 이 프로젝트에서 가장 값진 규칙입니다.